



UNIVERSIDADE VIRTUAL DO ESTADO DE SÃO PAULO
Eixo de Computação

Alcir Peterson Ribeiro, RA: 2011997
Emerson Nunes Barbosa, RA: 1823884
Julio Cesar Lima da Silva, RA: 1834990
Renan Rodrigues Tartari, RA: 2008791

PI-IV- Análise do consumo de energia elétrica na região de Guarulhos

Vídeo de apresentação do Projeto Integrador: <https://youtu.be/NUAZgdddddlo>

Guarulhos - SP
2023

Alcir Peterson Ribeiro, RA: 2011997
Emerson Nunes Barbosa, RA: 1823884
Julio Cesar Lima da Silva, RA: 1834990
Renan Rodrigues Tartari, RA: 2008791

PI-IV- Análise do consumo de energia elétrica na região de Guarulhos

Relatório Técnico-Científico apresentado na disciplina de Projeto Integrador IV para o curso de Bacharelado em Tecnologia da Informação, Bacharelado em Ciências de Dados e Bacharelado em Engenharia da Computação da Universidade Virtual do Estado de São Paulo (UNIVESP).

Resumo

Nosso objetivo com o projeto Integrador IV, é realizar análises de dados de distribuição de energia elétrica em larga escala e apresentar visualmente essas análises. Optamos por utilizar uma base de dados pública da ANEEL, que considera o consumo de energia das residências na região de Guarulhos. Através desses dados, serão realizadas análises para agrupar o consumo de energia por microrregião e identificar padrões sazonais e variações no consumo ao longo dos anos.

Utilizaremos para esse trabalho o AutoML (Automated Machine Learning) que é um conjunto de técnicas e ferramentas que automatizam o processo de construção e seleção de modelos de aprendizado de máquina. O objetivo do AutoML é simplificar e acelerar o desenvolvimento de modelos de machine learning, tornando-o mais acessível mesmo para usuários sem conhecimentos avançados em ciência de dados.

Usaremos o Power BI que é uma ferramenta poderosa para transformar dados em informações visualmente atraentes e interativas. Ele nos auxilia-rá na criação dos painéis de controle, relatórios e análises avançadas, facilitando a compreensão e interpretação dos dados que iremos analisar.

Palavras-chave: Consumo; Energia; AutoML; Ciencia de dados; Power Bi.

Abstract

Our objective with the IV Integrating Project is to carry out electricity distribution data on a large scale electricity distribution and visually present these analyzes. We chose to use an Aneel public database, which considers the energy consumption of homes in the Guarulhos region. Through this data, analyzes will be performed to group energy consumption by microregion and identify seasonal patterns and variations in consumption over the years.

We will use Automated Machine Learning (Automated Machine), which is a set of techniques and tools that automate the construction and selection process of machine learning models. The goal of Automl is to simplify and accelerate the development of Machine Learning models, making it more accessible even for users without advanced knowledge in data science.

We will use Power BI which is a powerful tool to turn data into visually attractive and interactive information. He assists us in the creation of advanced control panels, reports and analyzes, facilitating the understanding and interpretation of the data that we will analyze.

Keywords: Consumption; Energy; Auto; Data science; Power bi.

Lista de ilustrações

Figura 1 – Tela de criação de conta do Microsoft Azure	24
Figura 2 – Tela para criação de um recurso no Azure	25
Figura 3 – Tela para a criação do recurso Azure Machine Learning	26
Figura 4 – Tela para a criação do Azure Machine Learning Workspace	27
Figura 5 – Formulário de criação de espaço de trabalho AMLS preenchido	28
Figura 6 – Tela do Azure Machine Learning Workspace	29
Figura 7 – Página inicial e navegação do AML studio	29
Figura 8 – Criando uma instância de computação	31
Figura 9 – Configurações da instância de computação	32
Figura 10 – Criando um “cluster” de computação	33
Figura 11 – Configurações do cluster de computação – parte 1	34
Figura 12 – Configurações do cluster de computação – parte 2	35
Figura 13 – Nomeando e descrevendo seu conjunto de dados	36
Figura 14 – Selecionando a origem dos dados	37
Figura 15 – Selecionando o datastore	37
Figura 16 – Carregando dados para nosso armazenamento de dados	38
Figura 17 – Configurações dos arquivos	39
Figura 18 – Selecionando suas colunas	39
Figura 19 – Confirmando os detalhes do nosso conjunto de dados	40
Figura 20 – Gerando o “profile” dos dados carregados	41
Figura 21 – O processo do AutoML do Azure	41
Figura 22 – Iniciando sua execução de treinamento do AutoML	45
Figura 23 – Selecionando nosso conjunto de dados para treinamento	46
Figura 24 – Configurando nossa execução do AutoML	47
Figura 25 – Selecionando o tipo de tarefa correta	48
Figura 26 – Selecionando os tipos de validação e teste	49
Figura 27 – Tela com o último JOB executado	50
Figura 28 – Tela com os modelos	51
Figura 29 – Tela “Data guardrails”	51
Figura 30 – Tela com os modelos gerados	52
Figura 31 – Métricas do modelo	53
Figura 32 – Tela “Model performance”	56
Figura 33 – Tela “Dataset explorer”	56
Figura 34 – Tela “Aggregate feature importance”	57
Figura 35 – Tela “Individual feature importance”	58
Figura 36 – Inserção de Dados no PowerBi a partir de arquivos CSV	59
Figura 37 – Tratativa dos dados para apresentação visual da aplicação	59

Figura 38 – Montagem do Painel no PowerBi com utilização de Mapa, Tabela, Filtros e TreeMap destacados na ferramenta de opções do PowerBI	60
Figura 39 – Painel “Consumo por Residência” Análise de consumo de energia elétrico por residência por CEP	61
Figura 40 – Painel “Faixa de consumo por Localização” Análise com Visão TreeMap das faixas de consumo da cidade de Guarulhos	61
Figura 41 – Painel “Qualidade da Energia elétrica” Visualização da qualidade de fornecimento de energia elétrica na cidade de Guarulhos	62
Figura 42 – “Painel Consumo Por Residência” com o filtro de localidades	62

Sumário

1	INTRODUÇÃO	8
2	OBJETIVOS	9
3	JUSTIFICATIVA E DELIMITAÇÃO DO PROBLEMA	10
4	PROBLEMA DE PESQUISA	11
5	FUNDAMENTAÇÃO TEÓRICA	12
5.1	Inteligência Artificial (IA)	12
5.2	Python	12
5.3	Métodos estatísticos e matemática	13
5.4	Aprendizado de máquina	14
5.4.1	Tipos de aprendizado de máquina	15
5.4.2	Aprendizagem supervisionada	15
5.4.3	Aprendizagem não supervisionada	15
5.4.4	Aprendizagem por reforço	15
5.4.5	Pipeline de aprendizado de máquina	15
5.5	Engenharia de dados	16
5.6	Análise de dados	17
5.6.1	O processo de análise de dados	18
5.6.1.1	Requisitos de dados	18
5.6.1.2	Coleta de dados	18
5.6.1.3	Processamento de dados	19
5.6.1.4	Limpeza de dados	19
5.6.1.5	Análise exploratória de dados	19
5.6.1.6	Modelagem e algoritmos	20
5.6.1.7	Comunicação	20
5.7	KDD (Knowledge Discovery in Databases)	21
6	METODOLOGIA	22
6.1	Agrupamento	23
6.1.1	K-means	23
7	DESENVOLVIMENTO DA SOLUÇÃO	24
7.1	Introdução ao Serviço Azure Machine Learning	24
7.1.1	Criando nosso espaço de trabalho AMLS	24
7.1.1.1	Criando uma conta do Azure	24
7.1.1.2	Criando um espaço de trabalho AMLS	25

7.1.1.3	Navegando no estúdio AML	28
7.1.2	Criando computação para a execução dos nossos trabalhos do AutoML .	29
7.1.2.1	Criando uma instância de computação	30
7.1.2.2	Criando um cluster de computação	32
7.1.3	Trabalhando com dados no AMLS	35
7.1.3.1	Criando um conjunto de dados usando a GUI	35
7.1.4	Noções básicas sobre como o AutoML funciona no Azure	41
7.1.4.1	Garantindo a qualidade dos dados com “Data Guardrails”	41
7.1.4.2	Melhorando os dados com “Intelligent Feature Engineering”	42
7.1.4.3	Normalização de dados para ML com Iterative Data Transformation . . .	43
7.1.4.4	Treinando modelos rapidamente com Iterative ML Model Building	43
7.1.4.5	Obtendo os melhores resultados com o ML model ensembling	44
7.2	Treinando o modelo no AutoML	44
7.2.1	Criando uma solução AutoML	44
8	RESULTADOS	50
8.1	Interpretando nossos resultados do AutoML	50
8.1.1	Entendendo as proteções de dados (Data Guardrails)	51
8.1.2	Entendendo as métricas do modelo	52
8.1.3	Explicando nosso modelo AutoML	55
8.2	PowerBI	58
8.2.1	Desenvolvimento dos dashboards	59
9	CONCLUSÃO	63
	Referências	64

1 INTRODUÇÃO

O curso Projeto Integrador IV visa o desenvolvimento de análise de dados de distribuição de energia elétrica em larga escala e apresentação visual dessas análises. Com base nesse objetivo o grupo optou por utilizar uma base pública de dados da ANEEL (*agência nacional de energia elétrica*) disponibilizado no portal de acesso à informação do Governo Federal. A base a ser estudada leva em consideração o consumo das residências na região de Guarulhos, região escolhida por fazer parte do polo dos integrantes. Com os dados fornecidos realizaremos diversas análises clusterizando os grupos de consumo de acordo com seu consumo e microrregião verificando se em determinado período do ano há um maior consumo e ainda se houve crescimento do consumo entre os anos.

Além dessas análises básicas será possível verificar se a qualidade fornecida para esse bem de consumo essencial à população que a companhia prestadora do serviço está dentro dos padrões aceitáveis para a população.

Com base em nosso aprendizado durante as matérias do curso, o desenvolvimento dessa análise de dados e disponibilização de um BI (*Business Intelligence*) será finalizado e apresentado até a apresentação final do projeto.

2 OBJETIVOS

Objetivo Geral:

Desenvolver análise de dados em escala utilizando conjunto de dados existentes disponibilizado pelos órgãos públicos da ANEEL em parceria das distribuidoras que detém a concessão da distribuição de energia elétrica, liberados no portal de acesso à informação apresentando os dados de forma gráfica a partir de dashboards elaborados por meio da ferramenta de Power BI.

Os objetivos específicos são definir e analisar o consumo de energia elétrica das residências de Guarulhos, e realizar as análises a partir dos dados disponibilizados de forma sazonal, informando o consumo elétrico mensal ao longo do ano de 2021 e 2022. A partir de tais dados é esperado que sejam realizados clusterizações e análises demográficas a partir da análise dos dados disponíveis.

O grupo espera apresentar um dashboard elaborado do consumo de energia elétrica da região de Guarulhos com o apoio de ferramentas de visualização e tratamento de dados como o PowerBi disponibilizando para os usuários da aplicação alternativas de visualização dos dados e interação com os mesmos.

3 JUSTIFICATIVA E DELIMITAÇÃO DO PROBLEMA

A energia elétrica é definida como um bem de consumo básico para a sociedade. O maior consumo elétrico de energia apresenta condições de vida melhores e mais confortáveis. Com isso o grupo realizará análises dos dados em larga escala observando as métricas de consumo residencial disponibilizados pela base de dados e analisará o crescimento ou diminuição nesse item considerado básico para a população. Além de analisar os índices de qualidade como DIC (Duração de interrupção individual por unidade consumidora) e FIC (Frequência de interrupção individual por unidade consumidora) e verificar se estão dentro dos limites operacionais aceitáveis.

A relevância social leva em consideração onde às comunidades mais carentes estão agrupadas na região de Guarulhos observando o número de residenciais na região e o fator de capacidade do consumo elétrico, levando análises se é necessário maiores atenções de investimento para desenvolvimento das comunidades.

4 PROBLEMA DE PESQUISA

Uma análise em larga escala dos dados de consumo residencial será realizada, a fim de verificar se o consumo de energia elétrica aumentou ou diminuiu nos últimos anos e quais fatores podem estar influenciando essa tendência. Além disso, será avaliado se os índices de qualidade, como DIC e FIC, estão dentro dos limites operacionais aceitáveis e se a população está recebendo um fornecimento de energia elétrica de qualidade, fundamental para uma vida confortável e segura.

5 FUNDAMENTAÇÃO TEÓRICA

A ciência de dados é usada de várias maneiras. Alguns cientistas de dados se concentram no lado analítico das coisas, extraindo padrões e insights ocultos dos dados e, em seguida, comunicando esses resultados com visualizações e estatísticas. Outros trabalham na criação de modelos preditivos para prever eventos futuros, como prever se alguém colocará painéis solares em sua casa. Ainda outros trabalham em modelos de classificação; por exemplo, classificando a marca e o modelo de um carro em uma imagem. Uma coisa une todas as aplicações da ciência de dados: os dados. Em qualquer lugar onde você tenha dados suficientes, você pode usar a ciência de dados para realizar coisas que parecem mágicas para o observador casual. (MUKUNTHU; SHAH; TOK, 2019)

Drew Conway é famoso por seu diagrama de Venn de ciência de dados de 2010, postulando que a ciência de dados é uma combinação de habilidades de hacking (programação/codificação), matemática e estatística e conhecimento de domínio. podemos ainda adicionar perspicácia nos negócios e habilidades de comunicação à mistura e afirmaria que, às vezes, a experiência no domínio não é realmente necessária antecipadamente. Para utilizar a ciência de dados de forma eficaz, devemos saber como programar, conhecer um pouco de matemática/estatística, saber como resolver problemas de negócios com ciência de dados e saber como comunicar resultados.(MUKUNTHU; SHAH; TOK, 2019)

5.1 Inteligência Artificial (IA)

A inteligência artificial (IA) engloba o aprendizado de máquina e aprendizado profundo e, muitas vezes, tecnologias de nuvem para implantação. Trabalhos relacionados a IA têm títulos como “engenheiro de inteligência artificial” e “arquiteto de inteligência artificial”. Essa especialização se sobrepõe bastante ao aprendizado de máquina, aprendizado profundo e PNL. No entanto, existem alguns métodos específicos de IA, como o path finding, que são úteis para áreas como a robótica.

5.2 Python

É uma das principais linguagens de programação e ferramenta para realizar ciência de dados. Isso se deve em grande parte aos efeitos de rede, o que significa que quanto mais pessoas usam o Python, melhor ferramenta o Python se torna. À medida que a rede e a tecnologia Python crescem, ela se torna uma bola de neve e se auto-reforça. Os efeitos de rede surgem devido ao grande número de bibliotecas e pacotes, usos relacionados do Python (por exemplo, DevOps, serviços em nuvem e sites de atendimento), a grande e crescente comunidade em torno do Python e a facilidade de uso do Python. Python e as bibliotecas e pacotes de ciência de dados baseados em Python são gratuitos e de código aberto, ao contrário de muitas soluções GUI (como Excel ou RapidMiner). (SAYYERS, 2021)

É uma linguagem muito fácil de aprender e fácil de usar. Isso se deve em grande parte à sintaxe do Python – não há muitos colchetes para acompanhar (como em Java) e o estilo geral é limpo e simples. A equipe principal do Python também publicou um guia de estilo oficial, PEP 8, que afirma que o Python deve ser fácil de ler (e, portanto, fácil de escrever). A facilidade de aprender e usar Python significa que mais pessoas podem ingressar na comunidade Python mais rapidamente, aumentando a rede.

Ele já existe há algum tempo, e por isso houve tempo suficiente para as pessoas construírem bibliotecas convenientes para cuidar de tarefas que costumam ser tediosas e envolvem muito trabalho. Um exemplo é o pacote Seaborn para plotagem, *Análise e visualização exploratória de dados*. No início dos anos 2000, a principal maneira de fazer gráficos em Python era com o pacote Matplotlib, que às vezes era um pouco trabalhoso de usar. Seaborn foi criado por volta de 2013 e abstrai várias linhas de código Matplotlib em comandos únicos. Esse tem sido o caso geral do Python na ciência de dados. Agora temos pacotes e bibliotecas para fazer todo tipo de coisa, como AutoML (H2O, AutoKeras), plotagem (Seaborn, Plotly), interação com a nuvem por meio de kits de desenvolvimento de software ou SDKs (Boto3 para AWS, SDKs do Azure da Microsoft) e muito mais. Compare isso com outra linguagem de ciência de dados de ponta, R, que não tem “efeitos de rede” tão fortes. A AWS não oferece um R SDK oficial, por exemplo, embora exista um R SDK não oficial. (SAYYERS, 2021)

5.3 Métodos estatísticos e matemática

Como sabemos, a ciência de dados nasceu da estatística e da ciência da computação. Uma boa compreensão de algumas métodos estatísticos básicos é uma obrigação para fazer ciência de dados. Algumas dessas habilidades estatísticas essenciais incluem:

- Estatísticas de análise exploratória (análise de dados exploratórios ou EDA), como gráficos estatísticos e cálculos agregados, como quantis
- Testes estatísticos e seus princípios, como valores p, testes qui-quadrado, testes t e ANOVA
- Modelagem de aprendizado de máquina, incluindo métodos de regressão, classificação e agrupamento
- Probabilidade e distribuições estatísticas, como distribuições gaussianas e de Poisson

Com métodos e modelos estatísticos, podemos fazer coisas incríveis, como prever eventos futuros e descobrir padrões ocultos nos dados. Descobrir esses padrões pode levar a informações valiosas que podem mudar a maneira como as empresas operam e melhorar os resultados financeiros ou melhorar os diagnósticos médicos, entre outras coisas.

Embora não seja necessária uma extensa formação em matemática, é útil ter uma mentalidade analítica. Os recursos de um cientista de dados podem ser aprimorados com a compreensão de técnicas matemáticas, como:

- Geometria (por exemplo, cálculos de distância como distância euclidiana)
- Matemática discreta (para calcular probabilidades)
- Álgebra linear (para redes neurais e outros métodos de aprendizado de máquina)
- Cálculo (para treinar/otimizar alguns modelos, especialmente redes neurais)

Muitos dos aspectos mais difíceis dessas técnicas matemáticas não são necessárias para fazer a maior parte da ciência de dados. Por exemplo, saber álgebra linear e cálculo é mais útil para aprendizado profundo (redes neurais) e visão computacional, mas não é necessário para a maioria dos trabalhos de ciência de dados.

5.4 Aprendizado de máquina

O aprendizado de máquina é uma parte importante da ciência de dados e existem até cargos para pessoas especializadas em aprendizado de máquina chamado de “engenheiro de aprendizado de máquina” ou similar. Engenheiros de aprendizado de máquina ainda usará outras técnicas de ciência de dados, como “data munging”, mas terá amplo conhecimento dos métodos de aprendizado de máquina. O campo de aprendizado de máquina também está se movendo em direção à “deployment”, o que significa a capacidade de implantar modelos de aprendizado de máquina em escala. Isso geralmente usa a nuvem com interfaces de programação de aplicativos (APIs), o que permite engenheiros de software ou outros acessarem modelos de aprendizado de máquina, como costumam ser chamados MLOps. No entanto, não se pode implantar bons modelos de aprendizado de máquina sem primeiro se conhecer os fundamentos do aprendizado de máquina. Um cientista de dados deve ter conhecimentos e habilidades de aprendizado de máquina como parte de seu conjunto de habilidades principais. (SAYYERS, 2021)

O termo aprendizado de máquina foi cunhado por Arthur Samuel (1959), ele é um pioneiro americano no campo de jogos de computador e inteligência artificial (IA) e afirmou que “dá aos computadores a capacidade de aprender sem ser explicitamente programado”.(SAYYERS, 2021)

E em 1997, Tom Mitchell deu uma definição matemática e relacional “bem colocada” de que “Diz-se que um programa de computador aprende com a experiência E com relação a alguma tarefa T e alguma medida de desempenho P, se seu desempenho em T, conforme medido por P, melhora com a experiência E.”(SAYYERS, 2021)

Aprendizado de máquina é o campo de estudo em que algoritmos e modelos estatísticos aprendem e melhoram automaticamente a partir dos dados com padrões e inferência subjacentes, sem instrução explícita programada.(SAYYERS, 2021)

5.4.1 Tipos de aprendizado de máquina

Aprendizado de máquina é um amplo campo de estudo e é dividido em vários tipos, dependendo de alguns parâmetros como:

- 1) Tipo de dados de entrada (dados rotulados ou não rotulados)
- 2) O tipo de dados de saída (contínuo ou categórico)

5.4.2 Aprendizagem supervisionada

O aprendizado supervisionado é um tipo de classe de aprendizado de máquina que aprende com os dados rotulados. Os dados rotulados são um tipo de dados que possuem parâmetros de entrada e saída. Classificação e regressão são os principais tipos de problema de Aprendizagem Supervisionada.(SAYYERS, 2021)

5.4.3 Aprendizagem não supervisionada

O aprendizado não supervisionado é um tipo de classe de aprendizado de máquina que aprende com os dados não rotulados. Dados não rotulados são um tipo de dado que não possui parâmetro de saída. Agrupamento (Clustering), detecção de anomalias são alguns problemas de aprendizagem não supervisionada. Existe uma outra classe de aprendizado de máquina, que se assemelha ao aprendizado supervisionado e não supervisionado, conhecida como aprendizado semi-supervisionado.(SAYYERS, 2021)

5.4.4 Aprendizagem por reforço

Aprendizado por reforço é um tipo de aprendizado de máquina onde os algoritmos podem aprender com o ambiente e maximizar a recompensa. Alguns dos algoritmos mais conhecidos para aprendizagem por reforço são Q-Learning, SARSA, DQN, etc..(SAYYERS, 2021)

5.4.5 Pipeline de aprendizado de máquina

O aprendizado de máquina tem seu pipeline separado e é um pipeline geral para a maioria dos projetos. Este pipeline não é seguido palavra por palavra, mas é uma estrutura geral. Todo praticante de aprendizado de máquina segue uma versão modificada de um pipeline semelhante, conforme indicado abaixo:(SAYYERS, 2021)

- **Preparação de dados** : a preparação de dados é o processo pelo qual podemos preparar os dados para treinar, testar e validar o modelo de ML.
- **Extração de recursos** : a extração de recursos é o processo pelo qual selecionamos, modificamos os recursos certos para treinar o modelo. Pode haver poucos recursos que tenham uma contribuição para a saída (o que iremos prever usando o modelo), e alguns recursos não têm contribuição direta ou indireta para a variável de saída. A partir desta etapa, selecionaremos os recursos que não são necessários.
- **Modelo** : o modelo de aprendizado de máquina é uma representação matemática aprendida/formada a partir do padrão dos dados, que é fornecida como entrada para o treinamento do modelo.
- **Treinamento de modelo** : o treinamento de modelo é um processo para aprender o padrão subjacente dos dados com o recurso de saída fornecido (para aprendizado supervisionado).
- **Dados de teste** : este é um subconjunto de todo o conjunto de dados. Esses dados não são fornecidos como entrada para a fase de treinamento do modelo. Esses dados serão usados para encontrar a precisão do modelo para os dados não vistos.
- **Previsão** : A previsão é o processo; geralmente usamos os dados de teste/invisíveis para ver como o modelo está sendo executado.
- **Avaliação** : Esta é a etapa onde podemos ver a qualidade do modelo usando diferentes métricas como exatidão, recall, precisão, etc.

5.5 Engenharia de dados

Os engenheiros de dados são como encanadores de dados, mas se isso parece chato, não se deixe enganar – a engenharia de dados é, na verdade, um trabalho agradável e divertido. Engenharia de dados abrange habilidades frequentemente usadas nas primeiras etapas do processo de ciência de dados. São tarefas como coletar, organizar, limpar e armazenar dados em bancos de dados, e são os tipos de coisas que os cientistas de dados gastam uma grande fração de seu tempo. Os engenheiros de dados têm habilidades em Linux e na linha de comando, semelhantes ao pessoal do DevOps. Os engenheiros de dados também são capazes de implantar modelos de aprendizado de máquina em escala como engenheiros de aprendizado de máquina, mas um engenheiro de dados geralmente não tem tanto conhecimento amplo de modelos de ML quanto um engenheiro de ML ou um cientista de dados geral. Como cientista de dados, deve-se conhecer habilidades básicas de engenharia de dados, como interagir com diferentes bancos de dados por meio do Python e como manipular e limpar dados.(BEACH, 2022)

5.6 Análise de dados

Levando em consideração o vasto campo analítico da ciência de dados, é possível notar diferentes perspectivas de observação. Cientistas de Dados tem o árduo trabalho de trazerem luz a diferentes situações correlacionais, em constante confronto analítico, emergem insights facilitadores que proporcionam uma visão mais abrangente da ciência dos dados, esses resultados são documentados e apresentados por meio de visualizações e estatísticas. Alguns cientistas de dados optam por trabalharem com modelos de análises preditivas, buscando prever possíveis eventos e por vezes consolidá-los ou evitá-los, outros escolhem o modelo classificatório de dados, por exemplo, classificando regiões e população em imagens. Essas diferentes perspectivas de observadores unem o ponto de vista analítico dos cientistas de dados trazendo o foco para uma percepção mais sensível aos pormenores analíticos de um determinado banco de dados. (SCRATCH, 2020)

Levando em consideração o total de atributos necessários para descrever um cientista de dados nos deparamos com diferentes nichos de habilidades conjuntas que trabalham de forma correlacional ao dia a dia do cientista de dados, DREW CONWAY catalogou que a ciência de dados demandam das seguintes atribuições, a combinação de, habilidades de Hacking, (codificação e programação), matemática, estatística e domínio de conhecimento aplicado. Para a aplicação eficaz e eficiente da Ciência de Dados faz-se necessário o uso adequado das habilidades citadas, o bom senso a ética e o conhecimento aplicado se fazem presentes em todo o caminho do cientista de dados, seja analisando, resolvendo problemas ou comunicando situações. (SCRATCH, 2020)

A análise de dados é um processo de inspeção, limpeza, transformação e modelagem de dados com o objetivo de descobrir informações úteis, informar conclusões e apoiar a tomada de decisões. A análise de dados tem múltiplas facetas e abordagens, abrangendo diversas técnicas sob uma variedade de nomes e é usada em diferentes domínios de negócios, ciências e ciências sociais. No mundo dos negócios de hoje, a análise de dados desempenha um papel importante na tomada de decisões mais científicas e ajudando as empresas a operar de forma mais eficaz. (SCRATCH, 2020)

A mineração de dados é uma técnica específica de análise de dados que se concentra na modelagem estatística e na descoberta de conhecimento para fins preditivos e não puramente descritivos, enquanto a inteligência de negócios abrange a análise de dados que depende muito da agregação, focando principalmente nas informações de negócios. Em aplicações estatísticas, a análise de dados pode ser dividida em estatística descritiva, análise exploratória de dados (EDA) e análise de dados confirmatória (CDA). A EDA se concentra na descoberta de novos recursos nos dados, enquanto a CDA se concentra na confirmação ou falsificação de hipóteses existentes. Análise preditiva concentra-se na aplicação de modelos estatísticos para previsão ou classificação preditiva, enquanto a análise de texto aplica técnicas estatísticas, linguísticas e estruturais para extrair e classificar

informações de fontes textuais, uma espécie de dados não estruturados.(SCRATCH, 2020)

5.6.1 O processo de análise de dados

Análise , refere-se a dividir um todo em seus componentes separados para exame individual. A análise de dados , é um processo para obtenção de dados brutos , e posteriormente convertê-los em informações úteis para a tomada de decisão pelos usuários. Os dados são coletados e analisados para responder perguntas, testar hipóteses ou refutar teorias.(SCRATCH, 2020)

O estatístico John Tukey , definiu a análise de dados em 1961, como:

“Procedimentos para analisar dados, técnicas para interpretar os resultados de tais procedimentos, formas de planejar a coleta de dados para tornar sua análise mais fácil, mais precisa ou mais exata, e todo o maquinário e resultados de estatísticas (matemáticas) que se aplicam à análise de dados.” (SCRATCH, 2020)

Existem várias fases que podem ser distinguidas, descritas abaixo. As fases são iterativas , pois o feedback das fases posteriores pode resultar em trabalho adicional nas fases anteriores. O framework CRISP , utilizado em mineração de dados , possui etapas semelhantes.(SCRATCH, 2020)

5.6.1.1 Requisitos de dados

Os dados são necessários como entradas para a análise, que é especificada com base nos requisitos daqueles que direcionam a análise (ou clientes, que usarão o produto final da análise). O tipo geral de entidade sobre a qual os dados serão coletados é chamado de unidade experimental (por exemplo, uma pessoa ou população de pessoas). Variáveis específicas relativas a uma população (por exemplo, idade e renda) podem ser especificadas e obtidas. Os dados podem ser numéricos ou categóricos (ou seja, um rótulo de texto para números).(MUKUNTHU; SHAH; TOK, 2019)

5.6.1.2 Coleta de dados

Os dados são coletados de várias fontes. Os requisitos podem ser comunicados pelos analistas aos depositários dos dados; como, pessoal de Tecnologia da Informação dentro de uma organização. Os dados também podem ser coletados de sensores no ambiente, incluindo câmeras de trânsito, satélites, dispositivos de gravação, etc. Também podem ser obtidos por meio de entrevistas, downloads de fontes on-line ou leitura de documentação. (MUKUNTHU; SHAH; TOK, 2019)

5.6.1.3 Processamento de dados

As fases do ciclo de inteligência usadas para converter informações brutas em inteligência ou conhecimento acionável são conceitualmente semelhantes às fases da análise de dados.

Os dados, quando obtidos inicialmente, devem ser processados ou organizados para análise. Por exemplo, isso pode envolver a colocação de dados em linhas e colunas em um formato de tabela (conhecido como dados estruturados) para análise posterior, geralmente por meio do uso de planilhas ou software estatístico.(MUKUNTHU; SHAH; TOK, 2019)

5.6.1.4 Limpeza de dados

Uma vez processados e organizados, os dados podem estar incompletos, conter duplicatas ou conter erros. A necessidade de limpeza de dados surgirá de problemas na forma como os dados são inseridos e armazenados. A limpeza de dados é o processo de prevenção e correção desses erros. As tarefas comuns incluem correspondência de registros, identificação de dados imprecisos, qualidade geral dos dados existentes, desduplicação e segmentação de colunas. Esses problemas de dados também podem ser identificados por meio de uma variedade de técnicas analíticas. Por exemplo; com informações financeiras, os totais de variáveis específicas podem ser comparados com números publicados separadamente que se acredita serem confiáveis. Valores incomuns, acima ou abaixo de limites pré-determinados, também podem ser revistos. Existem vários tipos de limpeza de dados, que dependem do tipo de dados no conjunto; podem ser números de telefone, endereços de e-mail, empregadores ou outros valores. Métodos de dados quantitativos para detecção de valores discrepantes podem ser usados para eliminar dados que parecem ter maior probabilidade de serem inseridos incorretamente. Verificadores ortográficos de dados textuais podem ser usados para diminuir a quantidade de palavras digitadas incorretamente. No entanto, é mais difícil dizer se as palavras em si estão corretas.(MUKUNTHU; SHAH; TOK, 2019)

5.6.1.5 Análise exploratória de dados

Depois que os conjuntos de dados são limpos, eles podem ser analisados. Os analistas podem aplicar uma variedade de técnicas, conhecidas como análise exploratória de dados , para começar a entender as mensagens contidas nos dados obtidos. O processo de exploração de dados pode resultar em limpeza de dados adicionais ou solicitações adicionais de dados; assim, a inicialização das fases iterativas mencionadas no parágrafo inicial desta seção. Estatísticas descritivas , como média ou mediana, podem ser geradas para auxiliar na compreensão dos dados. Visualização de dados também é uma técnica

utilizada, na qual o analista é capaz de examinar os dados em formato gráfico para obter insights adicionais, sobre as mensagens contidas nos dados. (SAYYERS, 2021)

5.6.1.6 Modelagem e algoritmos

Fórmulas ou modelos matemáticos (conhecidos como algoritmos) podem ser aplicados aos dados para identificar relações entre as variáveis; por exemplo, usando correlação ou causalidade . Em termos gerais, os modelos podem ser desenvolvidos para avaliar uma variável específica com base em outras variáveis contidas no conjunto de dados, com algum erro residual dependendo da precisão do modelo implementado (por exemplo , $\text{Dados} = \text{Modelo} + \text{Erro}$).

A estatística inferencial inclui a utilização de técnicas que medem as relações entre variáveis específicas. Por exemplo, a análise de regressão pode ser usada para modelar se uma mudança na publicidade (variável independente X) fornece uma explicação para a variação nas vendas (variável dependente Y). Em termos matemáticos, Y (vendas) é uma função de X (publicidade). Pode ser descrito como ($Y = aX + b + \text{erro}$), onde o modelo é projetado de tal forma que (a) e (b) minimizam o erro quando o modelo prevê Y para um determinado intervalo de valores de X . Os analistas também podem tentar construir modelos que sejam descritivos dos dados, com o objetivo de simplificar a análise e comunicar os resultados.(BEACH, 2022)

5.6.1.7 Comunicação

A visualização de dados é usada para ajudar a entender os resultados depois que os dados são analisados.

Uma vez que os dados são analisados, eles podem ser relatados em vários formatos aos usuários da análise para dar suporte aos seus requisitos. Os usuários podem ter feedback, o que resulta em análises adicionais. Como tal, grande parte do ciclo analítico é iterativo. (WIKIPÉDIA, 2023a)

Ao determinar como comunicar os resultados, o analista pode considerar a implementação de uma variedade de técnicas de visualização de dados para ajudar a comunicar a mensagem de forma mais clara e eficiente ao público. A visualização de dados usa exibições de informações (gráficos como tabelas e gráficos) para ajudar a comunicar as principais mensagens contidas nos dados. As tabelas são uma ferramenta valiosa, pois permitem que um usuário consulte e se concentre em números específicos; enquanto os gráficos (por exemplo, gráficos de barras ou gráficos de linhas) podem ajudar a explicar as mensagens quantitativas contidas nos dados. (WIKIPÉDIA, 2023a)

5.7 KDD (Knowledge Discovery in Databases)

KDD (Knowledge Discovery in Databases) é um processo de extração de conhecimento útil e compreensível a partir de grandes conjuntos de dados. Esse processo envolve várias etapas, incluindo seleção, pré-processamento, transformação, mineração de dados e interpretação dos resultados.(WIKIPÉDIA, 2023c)

O termo KDD foi originalmente proposto em 1989 por Gregory Piatetsky-Shapiro e William Frawley, e se tornou uma área de pesquisa ativa em Ciência da Computação e Engenharia de Dados.(WIKIPÉDIA, 2023c)

6 METODOLOGIA

A metodologia é um caminho em que descrevemos os métodos para realizarmos a pesquisa, e de que forma será construída a nossa pesquisa. Para Mazucato realizar uma pesquisa é necessário separar seu desenvolvimento em etapas, que devem ser construídas de forma organizada para ocorrer o surgimento da pesquisa e do conhecimento científico. (MAZUCATO, 2018)

Pesquisa é a atividade científica pela qual descobrimos a realidade. Partimos do pressuposto de que a realidade não se desvenda na superfície. Não é o que aparenta à primeira vista. Ademais, nossos esquemas explicativos nunca esgotam a realidade, porque esta é mais exuberante do que aqueles (...). A partir daí, imaginamos que sempre existe o que descobrir na realidade, equivalendo isto a aceitar que a pesquisa é um processo interminável. (DEMO, 1983)

A metodologia utilizada neste trabalho é guiada pelo processo de descoberta de conhecimento em bases de dados, do inglês Knowledge Discovery in Databases (KDD). De acordo com (FAYYAD, 1996), KDD é um processo não trivial que objetiva identificar padrões válidos, novos (antes desconhecidos), potencialmente úteis e, essencialmente, compreensíveis em bases de dados. Conforme mostrado na Figura 2 (FAYYAD, 1996), no processo de KDD os dados passam por várias etapas, a saber: seleção, pré-processamento, transformação e, mineração e geração de padrões, para depois estarem disponíveis como informação que pode ser visualizada e interpretada.

A mineração de dados é a análise de grandes conjuntos de dados a fim de encontrar relacionamentos inesperados e de resumir os dados de uma forma que eles sejam tanto úteis quanto compreensíveis às pessoas responsáveis pela análise dos dados. (WIKIPÉDIA, 2023d)

Devido a ampla área de aplicação da Mineração de Dados, seu estudo é frequentemente dividido em tarefas denidas com base no resultado esperado após o processo de mineração. Para cada tarefa há diversas técnicas e métodos a serem aplicados. Em termos de aprendizagem de máquina, estas técnicas e métodos tradicionalmente são divididas em:

- Aprendizado supervisionado (preditivo): os dados para treinamento dos modelos possuem rótulos, indicando a que classe pertencem as instâncias observadas. Novas classificações são feitas com base nas classes aprendidas na base de treinamento.
- Aprendizado não supervisionado (descritivo): não há rótulos nas instâncias da base de treinamento, portanto o objetivo é identificar classes, relações ou agrupamentos nos dados.

Neste trabalho, o objetivo é prever a tendencia do consumo de energia elétrica, portanto um exemplo de aprendizagem não supervisionada. Mais especificamente, este problema é definido como agrupamento, que será detalhado a seguir.

6.1 Agrupamento

Agrupamento é o método pelo qual os pontos de dados semelhantes no espaço n -dimensional são divididos em diferentes grupos. Os pontos de dados em cada grupo serão semelhantes entre si e serão diferentes dos outros grupos. (WIKIPÉDIA, 2023b)

6.1.1 K-means

O agrupamento K-means é um algoritmo de aprendizado de máquina não supervisionado para agrupar dados não rotulados em várias classes. (WIKIPÉDIA, 2023e)

K-means usa o conceito de centróides para atribuir classes/grupos aos pontos de dados. K representa o número total de agrupamentos, ou seja, K número de centróides. (WIKIPÉDIA, 2023e)

7 DESENVOLVIMENTO DA SOLUÇÃO

7.1 Introdução ao Serviço Azure Machine Learning

Para atingirmos os objetivos propostos no projeto integrador precisamos aprender a usar o **Automated Machine Learning (AutoML)**. Antes de podermos fazer isso, no entanto, precisamos aprender a usar o **Azure Machine Learning Service (AMLS)**. AMLS é a principal plataforma de ML da Microsoft na nuvem do Azure.


Começaremos criando uma conta do Azure e criando um espaço de trabalho AMLS. Depois de criar um espaço de trabalho, nós criaremos diferentes tipos de computação para executar código Python e trabalhos de ML remotamente usando um cluster de máquinas. Em seguida, trabalharemos com dados usando o conjunto de dados do Azure e as construções de armazenamento de dados.

7.1.1 Criando nosso espaço de trabalho AMLS

7.1.1.1 Criando uma conta do Azure

- 1) Para criar uma conta do Azure, navegaremos até <https://azure.microsoft.com>.
- 2) Clicamos no botão verde “**Start free**”, conforme mostrado na captura de tela a seguir. Depois de clicar neste botão, fomos solicitados a selecionar um endereço de e-mail associado à nossa conta da Microsoft:

Figura 1 – Tela de criação de conta do Microsoft Azure



Próprio autor

A Microsoft solicitará o preenchimento de algumas informações sobre nosso país, nome, sobrenome, endereço de e-mail e número de telefone. Nós teremos que verificar

nossa identidade por meio de um número de telefone e inserir as informações do nosso cartão de crédito.

Observe que nós não seremos cobrados pela criação de uma conta do Azure, a menos que atualize. Depois de assinarmos o contrato, nós teremos \$200 dólares de crédito gratuito para usar nos primeiros 30 dias do Azure. Não seremos cobrados automaticamente ao final do período de 30 dias. É possível também usar uma conta de estudante para utilizar os serviços do Azure, a Univesp possui parceria com a Microsoft o que possibilita a utilização do e-mail da universidade na criação da conta Microsoft, porém o crédito será de \$100 dólares.


Com uma conta implementada, agora poderemos criar recursos no Microsoft Azure.

7.1.1.2 Criando um espaço de trabalho AMLS

Depois de criarmos uma conta no Azure, criaremos um espaço de trabalho **Azure Machine Learning Service (AMLS)**. Um espaço de trabalho AMLS é um recurso centralizado para todo o nosso trabalho de ML no Azure. Ele também fornece acesso ao **estúdio AML**. Este estúdio é um portal web gráfico que permite acesso fácil e intuitivo a todos os diferentes componentes do espaço de trabalho do AMLS.


- 1) Iremos ao portal do Azure em <https://portal.azure.com>.
- 2) Clicamos no botão **“Create a resource”**. Os recursos são simplesmente serviços do Azure. Cada serviço do Azure, seja uma máquina virtual, banco de dados em nuvem ou ferramenta ML, conta como um recurso.

Figura 2 – Tela para criação de um recurso no Azure



- 3) Após clicarmos no botão, digitamos “**Machine Learning**” na caixa de pesquisa e pressionamos “**Enter**”. Veremos uma nova tela com um grande frasco azul no canto superior direito. Este é o símbolo AML.

Figura 3 – Tela para a criação do recurso Azure Machine Learning



Próprio autor

- 4) Clicamos em “**Create Azure Machine Learning**” na tela acima. Será apresentado uma tela solicitando que selecionemos uma assinatura, preencher um grupo de recursos, criar um nome de espaço de trabalho, selecionar uma região e selecionar uma edição de espaço de trabalho. Caso tenhamos várias assinaturas do Azure, selecionamos aquela associada a conta que gostaríamos de usar. Um grupo de recursos é simplesmente uma coleção de recursos do Azure. Criaremos um novo recurso seguindo as convenções de nomenclatura.

IMPORTANTE

Para esse projeto utilizaremos a seguinte nomenclatura: SiglaDoRecurso-ProjetoIntegrador. Ex: RG-PI-IV será o nome do grupo de recursos utilizado no projeto integrador IV.

Figura 4 – Tela para a criação do Azure Machine Learning Workspace

Microsoft Azure Upgrade Search resources, services, and docs (G+/I)

Home > Marketplace >

Azure Machine Learning

Create a machine learning workspace

Basics Networking Advanced Tags Review + create

Resource details

Every workspace must be assigned to an Azure subscription, which is where billing happens. You use resource groups like folders to organize and manage resources, including the workspace you're about to create. [Learn more about Azure resource groups](#)

Subscription * ⓘ Azure subscription 1

Resource group * ⓘ Create new

Workspace details

Configure your basic workspace settings like its storage connection, authentication, container, and more. [Learn more](#)

Workspace name * ⓘ

Region * ⓘ Brazil South

Storage account * ⓘ Create new

Key vault * ⓘ Create new

Application insights * ⓘ Create new

Container registry * ⓘ None Create new

Review + create < Previous Next : Networking

Próprio autor

- 5) Preenchemos o restante do formulário nomeando nosso espaço de trabalho AMLS e selecionando uma região. Escolhemos a região perto de onde moramos. Depois de preencher todos os valores, nosso formulário ficou conforme ao mostrado na captura de tela a seguir.

Observe que, além do espaço de trabalho AMLS, nós também estamos criando recursos adicionais automaticamente. Um registro de contêiner para manter o código em contêiner será criado automaticamente:

Figura 5 – Formulário de criação de espaço de trabalho AMLS preenchido

Azure Machine Learning ...
Create a machine learning workspace

Basics Networking Advanced Tags Review + create

Resource details

Every workspace must be assigned to an Azure subscription, which is where billing happens. You use resource groups like folders to organize and manage resources, including the workspace you're about to create. [Learn more about Azure resource groups](#)

Subscription * ⓘ Azure subscription 1 ▼

Resource group * ⓘ (New) RG-PI-IV ▼
[Create new](#)

Workspace details

Configure your basic workspace settings like its storage connection, authentication, container, and more. [Learn more](#)

Workspace name * ⓘ WS-PI-IV ✓

Region * ⓘ Brazil South ▼

Storage account * ⓘ (new) wspiiv4076405801 ▼
[Create new](#)

Key vault * ⓘ (new) wspiiv1332001943 ▼
[Create new](#)

Application insights * ⓘ (new) wspiiv0392949203 ▼
[Create new](#)

Container registry * ⓘ None ▼
[Create new](#)

Próprio autor

- 6) Concluimos a criação de nosso espaço de trabalho AMLS clicando em “Review + create”, seguido de “Create”.


A partir daí vemos uma tela que diz que a implantação está em andamento e quatro recursos diferentes do Azure foram criados. Isso incluirá nosso espaço de trabalho AMLS, uma instância de conta de armazenamento para armazenar nossos dados, uma instância Azure Key Vault para armazenar nossas senhas e um recurso do Application Insights para monitorando nossos Trabalhos de ML.

7.1.1.3 Navegando no estúdio AML

Com nosso espaço de trabalho AMLS criado, agora podemos navegar até o estúdio AML.

Navegamos até <https://ml.azure.com> ou abrimos nosso espaço de trabalho AMLS e clicamos no botão “**Launch Studio**”, que pode ser encontrado no meio da tela, conforme captura de tela abaixo:


Figura 6 – Tela do Azure Machine Learning Workspace



Próprio autor

A captura de tela a seguir mostra o estúdio e sua barra de navegação:

Figura 7 – Página inicial e navegação do AML studio



Próprio autor

7.1.2 Criando computação para a execução dos nossos trabalhos do AutoML


Navegamos até a guia Compute para criar uma instância de computação e um cluster de computação. Depois de abrir a guia, veremos quatro títulos na parte superior: Compute instances , Compute clusters , Inference clusters e Attached compute. Vamos dar uma olhada neles com mais detalhes:

- **Compute Instance** são máquinas virtuais que nós podemos usar para escrever e executar código Python em notebooks Jupyter ou JupyterLab; nós também podemos usar uma instância de computação para escrever código R usando o R Studio.
- **Compute clusters** são grupos de máquinas virtuais usadas para treinar modelos de ML remotamente. Nós podemos iniciar trabalhos em um cluster de computação e continuar trabalhando no código em sua instância de computação.
- **Inference Clusters** são grupos de máquinas virtuais usadas para pontuar dados em tempo real.
- **Attached Computer** refere-se ao uso do Databricks ou computação HDInsight para executar trabalhos de big data.

7.1.2.1 Criando uma instância de computação

- 1) Seleccionamos Compute e depois “Compute Instances”. Em seguida, clicamos no botão **New**, na tela a seguir:

Figura 8 – Criando uma instância de computação



Próprio autor

Selecionamos CPU para nosso tipo de máquina virtual e Standard_DS12_v2 como nosso tamanho de máquina virtual.

Para conjuntos de dados maiores, precisaremos de máquinas virtuais com mais RAM. Como diretriz aproximada, é recomendado ter 20 vezes mais RAM do que o tamanho dos dados no formato CSV. Após inserirmos as configurações, conforme mostrado na captura de tela a seguir, clicamos em “Next”:

IMPORTANTE – CPU VERSUS GPU

Para a maioria dos trabalhos de AutoML e ML, as CPUs serão suficientes. Ao treinar modelos de aprendizado profundo, no entanto, nós precisaremos selecionar as máquinas virtuais de GPU, neste trabalho utilizaremos CPU porque são mais baratas.

- 2) Informamos o nome da nossa instância de computação. Colocamos o nome CS-PI-IV e depois clicamos no botão “Create”:

Figura 9 – Configurações da instância de computação

Create compute instance

Required Settings

Configure required settings
Select the name and virtual machine size you would like to use for your compute instance. Please note that a compute instance can not be shared. It can only be used by a single assigned user. By default, it will be assigned to the creator and you can change this to a different user in the advanced settings section.

Compute name: CS-P1-V

Location: braziliouth

Virtual machine type: CPU

Virtual machine size: Select from recommended options

Name	Category	Workload types	Available quota	Cost
Standard_DS11_v2 2 cores, 14GB RAM, 20GB storage	Memory optimized	Development on Notebooks (or other IDE) and light weight testing	6 cores	\$0.24/hr
Standard_DS3_v2 4 cores, 14GB RAM, 20GB storage	General purpose	Classical ML model training on small datasets	6 cores	\$0.34/hr
Standard_DS12_v2 4 cores, 28GB RAM, 56GB storage	Memory optimized	Data manipulation and training on medium-sized datasets (1-10GB)	6 cores	\$0.47/hr
Standard_F4s_v2 4 cores, 8GB RAM, 32GB storage	Compute optimized	Data manipulation and training on large datasets (>10 GB)	6 cores	\$0.26/hr

Buttons: Create, Back, Next: Advanced Settings, Cancel


Próprio autor

7.1.2.2 Criando um cluster de computação

Nosso próximo passo foi criar um cluster de computação para poder executar nossos trabalhos do AutoML usando a interface visual.

- 1) Para criar um cluster de computação por meio da GUI, clicamos na guia Compute, depois em Compute clusters e, em seguida, clicamos no botão “New”, conforme mostrado na captura de tela a seguir:

Figura 10 – Criando um “cluster” de computação



Próprio autor

- 2) Há mais configurações quando se trata de criar um cluster de computação. Primeiro, criamos um nome seguindo a convenção de nomenclatura. Os clusters de computação só podem ter nomes com 16 caracteres. Nossa região foi selecionada automaticamente para que corresponda com nosso espaço de trabalho. Como fizemos anteriormente, selecionamos CPU como o tipo da máquina virtual e Standard_DS4_v3 como o tamanho da máquina virtual. Para prioridade de máquina virtual, selecionamos “Dedicated” em vez de “Low priority“. Os trabalhos executados em máquinas virtuais de baixa prioridade podem ser interrompidos em períodos de alto uso. Em seguida, clicamos em “Next”, conforme mostrado na captura de tela a seguir:

Figura 11 – Configurações do cluster de computação – parte 1

Create compute cluster

Virtual Machine

Advanced Settings

Select virtual machine

Select the virtual machine size you would like to use for your compute cluster.

Location *

Brazil South

Virtual machine tier

☒ Dedicated ☐ Low priority

Virtual machine type

☒ CPU ☐ GPU

Virtual machine size

☒ Select from recommended options ☐ Select from all options

Name	Category	Workload types	Available quota	Cost
☐ Standard_DS11_v2 2 cores, 14GB RAM, 28GB storage	Memory optimized	Development on Notebooks (or other IDE) and light weight testing	2 cores	\$0.24/hr
☒ Standard_DS4_v3 4 cores, 16GB RAM, 32GB storage	General purpose	Classical ML model training on small datasets	6 cores	\$0.32/hr
☐ Standard_E4as_v4 4 cores, 32GB RAM, 64GB storage	Memory optimized	Data manipulation and training on medium-sized datasets (1-10GB)	4 cores	\$0.40/hr
☐ Standard_F4s_v2 4 cores, 8GB RAM, 32GB storage	Compute optimized	Data manipulation and training on large datasets (>10 GB)	6 cores	\$0.26/hr

Back Next Cancel

Próprio autor

- 3) Na próxima página, nomeamos nosso cluster de computação seguindo a convenção de nomenclatura. Os clusters de computação só podem ter nomes com 16 caracteres. Em seguida, selecionamos o número de nós. Essa é a diferença mais importante entre clusters de computação e instâncias de computação. Com instâncias de computação, nós temos um único nó para executar nossos trabalhos; com clusters, nós podemos definir os números mínimo e máximo de nós e eles serão dimensionados automaticamente de acordo com nosso trabalho. O AutoML usa clusters de computação treinando modelos diferentes em paralelo em nós separados. Definimos nosso número mínimo de nós como **0** para minimizar nossos custos quando nenhuma tarefa estiver em execução e definimos nossa contagem máxima de nós como **1**, como utilizamos uma conta gratuita o limite máximo para de nodes é 1. Por fim, alteramos o número de segundos antes que os nós sejam reduzidos para **1200** segundos, ou **20** minutos, para evitar que nossas máquinas desliguem enquanto nós trabalhamos. Nossas configurações ficaram conforme mostradas na captura de tela a seguir, clicamos no botão **“Create”**:

Figura 12 – Configurações do cluster de computação – parte 2

Create compute cluster

Virtual Machine
Advanced Settings

Configure Settings
Configure compute cluster settings for your selected virtual machine size.

Name	Category	Cores	Available quota	RAM	Storage	Cost/Node
Standard_D4s_v3	General purpose	4	6 cores	16 GB	32 GB	\$0.32/hr

Compute name * CC-PI-IV

Minimum number of nodes * 0

Maximum number of nodes * 1

Idle seconds before scale down * 1200

☐ Enable SSH access

> Advanced settings

Add tags

Name	Value

☐ No tags

Back Create Download a template for automation Cancel

Próprio autor

7.1.3 Trabalhando com dados no AMLS

Agora que criamos uma computação, tudo o que precisamos fazer é criar um conjunto de dados e estaremos prontos para iniciarmos nossos trabalhos no AutoML. Conjuntos de dados são simplesmente ponteiros para arquivos em nossa conta de armazenamento ou ponteiros para consultas SQL em bancos de dados SQL do Azure.

Um conjunto de dados não é um arquivo em si. Nós podemos criar conjuntos de dados de arquivos locais, de consultas SQL ou de arquivos em nossas contas de armazenamento. Para este projeto integrador, usaremos um conjunto de dados abertos da utilização de energia elétrica no município de Guarulhos-SP.

7.1.3.1 Criando um conjunto de dados usando a GUI

- 1) Clicamos na guia “Data”, e depois no botão “Create”, no campo “Name” entramos o nome do nosso conjunto de dados (DS-PI-IV-TAB) e a descrição do mesmo. No campo “Type” escolhemos “Table (mltable)”, depois clicamos no botão “Next” conforme mostrado na captura de tela a seguir:

Figura 13 – Nomeando e descrevendo seu conjunto de dados

Create data asset

1 Data type

2 Data source

Set the name and type for your data asset

Name *

DS-PI-IV-TAB

Description

Data asset description

Type * ⓘ

Table (mtable)


Back

Next

Próprio autor

- 1) Na tela que se segue escolhemos a origem de nossos dados e para isso selecionamos o item “From local files”, em seguida clicamos no botão “Next”, conforme mostrado na captura de tela a seguir:


Figura 14 – Selecionando a origem dos dados



Próprio autor

- 3) Selecionamos o tipo de “Datastore” como sendo “Azure Blob Storage”, clicamos em “Next” conforme mostrado na captura de tela a seguir:

Figura 15 – Selecionando o datastore



Próprio autor

- 4) Clicamos no botão “Upload folder” para selecionarmos o arquivo (tbucbt) que será carregado no “workspace”, conforme demonstrado na captura de tela abaixo, em seguida clicamos no botão “Next”:

Figura 16 – Carregando dados para nosso armazenamento de dados

Create data asset

✓ Data type

✓ Data source

✓ Storage type

4 File or folder selection

5 Settings

6 Schema

7 Review

Choose a file or folder

Choose files or folders to upload from your local drive. If you upload multiple folders or files, they will be stored in a containing folder.

Upload path

azureml://subscriptions/4109955a-3dee-4b04-add0-28f5d7be11a1/resourcegroups/RG-PI-IV/workspa... 

Upload 

☐ Overwrite if already exists

Upload list

tbucbt.csv	✓ 880.56 MB/880.56 MB	...
------------	-----------------------	-----

Back

Next

Próprio autor

- 5) No passo “settings” verificamos as configurações do arquivos e clicamos no botão “Next” conforme demonstra a captura de tela a seguir:

Figura 17 – Configurações dos arquivos

Create data asset

☒ Data type
☒ Data source
☒ Storage type
☒ File or folder selection
☒ **Settings**
☐ Schema
☐ Review

Settings
These settings determine how the data is parsed. The initial settings are automatically detected; you can change them as needed to reparse the data.

File format: Delimiter: Example: Field1.Field2.Field3 Encoding:

Column headers: Skip rows:

☐ Dataset contains multi-line data ⓘ

ⓘ Note: Processing tabular files with multi-line data is slower because multiple CPU cores cannot be used to ingest the data in parallel. Checking this option may result in slower processing times.

Data preview

ogc_fid	objectid	dist	pac	pn_con	uni_tr_d	ctmt	uni_tr_s	sub	conj	mun	brr	cep	clas_sub	cnae
1	1	391	100183...	B00346...	165ET00...	RITQ1314	165TRIT...	ITQ	15864	3523107	VILA SA...	8599510	RE1	0000-4
2	2	391	100009...	B00378...	045ET00...	RGOP01...	045TRG...	GOP	13163	3518800	GOPOU...	7062010	RE1	0000-4
3	3	391	100197...	B00372...	045ET00...	RVGA01...	045TRV...	VGA	13143	3518800	VILA AU...	7025070	RE1	0000-4
4	4	391	100199...	B00375...	045ET00...	RBON01...	165TRB...	BON	13178	3518800	SITIO S...	7261340	CO1	6822-4
5	5	391	100168...	B00225...	175ET00...	RURB13...	175TRU...	URB	15863	3549904	PARQUE...	12246023	RE1	0000-4
6	6	391	100195...	B00371...	175ET00...	RURB13...	175TRU...	URB	15874	3549904	JARDIM ...	12200000	CO1	8211-3
7	7	391	100197...	B00374...	045ET00...	RVHE01...	045TRV...	VHE	13143	3518800	VILA AU...	7041220	RE1	0000-4
8	8	391	100047...	B00068...	175ET00...	RVSL1303	175TRV...	VSL	13145	3549904	TRINTA ...	12237010	RE1	0000-4
9	9	391	100170...	B00229...	165ET00...	RASP1306	165TRA...	ASP	15859	3523107	MORRO...	8572510	RE1	0000-4
10	10	391	100019...	B00029...	130ET00...	RMCI13...	130TRM...	MCI	13154	3530607	VILA M...	8717300	RE1	0000-4

Próprio autor

6) No passo “Schema” validamos os tipos de dados e clicamos no botão “Next”. Conforme demonstrado na captura de tela abaixo:

Figura 18 – Selecionando suas colunas

Create data asset

☒ Data type
☒ Data source
☒ Storage type
☒ File or folder selection
☒ Settings
☒ **Schema**
☐ Review

Schema
Column types are auto-detected based on the initial subset of the data and can be updated here. Values not aligning with the specified column type will fail conversion and would be either null-filled or replaced with error value. Any conversions preview errors are non-blocking and you can proceed.

Search column name

Include	Column name	Type	Example values	Date format ⓘ	Properties ⓘ
☐	Path	String		Not applicable to selected type	Not applicable to...
☒	ogc_fid	Integer	1, 2, 3	Not applicable to selected type	Not applicable to...
☒	objectid	Integer	1, 2, 3	Not applicable to selected type	Not applicable to...
☒	dist	Integer	391, 391, 391	Not applicable to selected type	Not applicable to...
☒	pac	Integer	1001832913, 1000096875, 1001970768	Not applicable to selected type	Not applicable to...
☒	pn_con	String	B003469697, B003788959, B003720999	Not applicable to selected type	Not applicable to...
☒	uni_tr_d	String	165ET005340219, 045ET002011259, 04...	Not applicable to selected type	Not applicable to...
☒	ctmt	String	RITQ1314, RGOP0113, RVGA0102	Not applicable to selected type	Not applicable to...
☒	uni_tr_s	String	165TRITQ00019, 045TRGOP00029, 045...	Not applicable to selected type	Not applicable to...
☒	sub	String	ITQ, GOP, VGA	Not applicable to selected type	Not applicable to...

Próprio autor

- 7) No passo “Review” validamos os dados e clicamos no botão “Create” para terminar a importação do arquivo para o Azure, como demonstrado na captura de tela abaixo:

Figura 19 – Confirmando os detalhes do nosso conjunto de dados

Create data asset

Review

Review the settings for your data asset and make any changes as needed.

Data type

Name
DS-PI-IV-TAB

Description
--

Type
tabular

Data source

Type
Local

File selection

Upload path
azureml://subscriptions/4109955a-3dee-4b04-add0-28f5d7be11a1/resourcegroups/RG-PI-IV/workspaces/WS-PI-IV/datastores/workspaceblobstore/paths/UI/2023-05-23_032031_UTC/tbucbt.csv

Files uploaded
tbucbt.csv

Storage

Datastore type
AzureBlob

Datastore name
workspaceblobstore

Schema

ogc_fid	Integer
objectid	Integer
dist	Integer
pac	Integer
pn_con	String

(showing 5 of 44 columns)

Back Create Cancel

Próprio autor

- 8) Clicando na guia “Explore” podemos ver que nosso arquivo de dados foi carregado com sucesso, agora geraremos o “Profile” com as 10.000 primeiras linhas, esse “profile” será utilizado para vermos o “schema” e o sumário das estatísticas dos dados completos para isso clicaremos no botão “Generate”, abaixo segue a captura de tela que evidência esse passo:

Figura 20 – Gerando o “profile” dos dados carregados

The screenshot shows the Azure ML 'Generate profile' dialog on the right and a data table on the left. The dialog has fields for 'Select compute type' (Compute cluster), 'Select Azure ML compute cluster' (CC-PI-IV), and 'Profile output location' (Datastore). The 'Generate' button is highlighted. The data table on the left has 14 columns: ogc_fid, objectid, dist, pac, pn_con, uni_tr_d, ctmt, uni_tr_s, sub, conj, mun, brr, cep. It shows the first 14 rows of data.

ogc_fid	objectid	dist	pac	pn_con	uni_tr_d	ctmt	uni_tr_s	sub	conj	mun	brr	cep
1	1	391	100183...	800346...	165ET00...	RITQ1314	165TRIT...	ITQ	15864	3523107	VILA SA...	8599510
2	2	391	100009...	800378...	045ET00...	RGOP01...	045TRIG...	GOP	13163	3518800	GOPOU...	7062010
3	3	391	100197...	800372...	045ET00...	RVGA01...	045STRV...	VGA	13143	3518800	VILA AU...	7025070
4	4	391	100199...	800375...	045ET00...	RBON01...	165STRB...	BON	13178	3518800	SITIO S...	7261340
5	5	391	100168...	800225...	175ET00...	RURB13...	175TRIU...	URB	15863	3549904	PARQUE...	12246023
6	6	391	100195...	800371...	175ET00...	RURB13...	175TRIU...	URB	15874	3549904	JARDIM...	12200000
7	7	391	100197...	800374...	045ET00...	RVHE01...	045STRV...	VHE	13143	3518800	VILA AU...	7041220
8	8	391	100047...	800068...	175ET00...	RVSL1303	175TRIV...	VSL	13145	3549904	TRINTA...	12237010
9	9	391	100170...	800229...	165ET00...	RASP1306	165TRA...	ASP	15859	3523107	MORRO...	8572510
10	10	391	100019...	800029...	130ET00...	RMC113...	130TRM...	MCI	13154	3530607	VILA M...	8717300
11	11	391	100192...	800355...	045ET00...	RVGA01...	045STRV...	VGA	13143	3518800	VILA AU...	7023022
12	12	391	100172...	800231...	165ET00...	RITQ1304	165TRIT...	ITQ	15864	3523107	JARDIM...	8595848
13	13	391	100177...	800236...	130ET00...	RBCU13...	130TRB...	BCU	13154	3530607	VILA PO...	8738570
14	14	391	100194...	800371...	045ET00...	RVGA01...	045STRV...	VGA	13143	3518800	VILA AU...	7025190

Próprio autor

7.1.4 Noções básicas sobre como o AutoML funciona no Azure

Antes de executarmos nosso experimento do AutoML, é importante entendermos como o AutoML funciona no Azure. Afinal, o AutoML é mais do que apenas aprendizado de máquina. É também sobre transformação e manipulação de dados.

Conforme mostrado no diagrama a seguir, nós podemos dividir os estágios do AutoML em aproximadamente cinco partes: Data Guardrails Check , Intelligent Feature Engineering , Iterative Data Transformation , Iterative ML Model Building e Model Ensemble. Somente no final desse processo o AutoML produz um melhor modelo definitivo:

Figura 21 – O processo do AutoML do Azure



Próprio autor

7.1.4.1 Garantindo a qualidade dos dados com “Data Guardrails”

“Data Guardrails” serve para deixar claro que nossos dados estão no formato correto para o AutoML e, se não estiverem, ele alterará os dados de acordo. Existem atualmente seis verificações principais que são realizadas em nossos dados. Duas das verificações – uma para detectar valores ausentes e outra para detectar colunas de alta cardinalidade –

ocorrerão em cada conjunto de dados. As outras quatro verificações dependem do problema ou da configuração.

A imputação de valores de recursos ausentes detectará quaisquer valores nulos em nosso conjunto de dados. A manipulação de recursos de alta cardinalidade, por outro lado, identificará todas as colunas categóricas com um grande número de valores exclusivos. Ambos são importantes para a próxima etapa; ou seja, Engenharia de recursos inteligentes.

Ao contrário das duas primeiras verificações, o tratamento da divisão de validação ocorrerá apenas se nós definirmos a configuração de validação como `auto`. Essa verificação divide automaticamente os dados em conjuntos de treinamento e teste para que nós não precisemos fazer isso. É uma das muitas maneiras pelas quais o AutoML acelera o processo de ciência de dados.

A detecção de balanceamento de classe é específica para problemas de classificação que estão tentando prever uma categoria, enquanto a detecção de problemas de memória e a detecção de frequência são específicas para problemas de previsão que estão tentando prever um número futuro.

7.1.4.2 Melhorando os dados com “Intelligent Feature Engineering”

Assim que nossos dados passarem pela verificação das proteções de dados, a próxima etapa é a engenharia de recursos inteligentes. Isso consiste em preenchimento de valores ausentes, tratamento de recursos categóricos de alta cardinalidade, geração de recursos adicionais e recursos categóricos de codificação “one-hot”. Técnicas de engenharia de recursos mais avançadas usando agrupamento k-means, peso de evidência e análise avançada de texto também são aplicadas aqui.

Para começar, todas as colunas consistindo em todos os valores ausentes, valores idênticos ou cardinalidade extremamente alta (campos de ID, GUIDs e assim por diante) serão removidas automaticamente. Em seguida, seus valores numéricos ausentes serão preenchidos com a média (média) da coluna, enquanto seus valores categóricos ausentes serão preenchidos com o valor mais comum.

Após a imputação de valor ausente, colunas adicionais serão geradas para recursos de data e hora e recursos de texto. Os recursos de data e hora incluem ano, mês, dia, dia da semana, dia do ano, trimestre, semana do ano, hora, minuto e segundo. Os recursos de texto incluem a frequência de termos para grupos de uma, duas e três palavras.

A codificação “one-hot” é então aplicada a todas as colunas categóricas. Simplificando, isso significa que colunas de 1s e 0s são criadas para representar cada valor exclusivo em sua coluna original. Se nossa coluna original for *animal*, um cachorro terá *1* na coluna de cachorro recém-criada e *0* em todas as outras colunas de animais. Colunas categóricas de alta cardinalidade terão colunas agrupadas (*cão-gato*) criadas em seu lugar.

7.1.4.3 Normalização de dados para ML com Iterative Data Transformation

Os modelos ML costumam ter um desempenho melhor quando dimensionamos os dados. Por exemplo, se nós tivermos uma coluna de dados numéricos com valores entre 5 e 10 e outra coluna com valores entre 1 e 10 milhões, geralmente é melhor normalizar cada coluna para que seu valor mínimo seja 0 e seu valor máximo seja 1. Existem muitos tipos de normalização e, felizmente, o AutoML executa-os para nós com a transformação de dados iterativa.

Sempre que o AutoML treina um novo modelo, ele começa dimensionando seus dados usando um dos sete métodos. Esses sete métodos são os seguintes:

- **StandardScaler**
- **MinMaxScaler**
- **Maximum absolute value scaler**
- **RobustScaler**
- **PCA**
- **Truncated Singular Value Decomposition**
- **SparseNormalizer**

Normalmente, nós teríamos que codificar e testar cada um deles para determinar qual método de escalonamento funciona melhor, mas com o AutoML, nós não precisamos pensar nisso.

7.1.4.4 Treinando modelos rapidamente com Iterative ML Model Building

O núcleo do Azure AutoML é uma construção de modelo de ML iterativa. O AutoML treinará modelos em paralelo em suas configurações de uma extensa lista de algoritmos. A equipe AutoML da Microsoft selecionou apenas os modelos de algoritmos de melhor desempenho para serem incluídos no AutoML e, antes de adicionar um novo, ele passa por testes extensivos. Isso garante alto desempenho do modelo.

Ao observar os modelos de treinamento do AutoML, nós notaremos com frequência que ele usa o mesmo algoritmo repetidamente. Nesse caso, ele está tentando diferentes combinações de hiperparâmetros para obter uma pontuação mais alta. Os hiperparâmetros são simplesmente configurações que nós podemos definir especificamente para um algoritmo, como a profundidade da árvore para árvores de decisão ou perda na descendência de gradiente estocástico.

Falando em pontuações, cada tipo de problema – regressão, classificação e previsão – tem diferentes métricas que nós podemos usar para pontuar. O AutoML também usa um conjunto diferente de algoritmos para cada tipo de problema.

7.1.4.5 Obtendo os melhores resultados com o ML model ensembling

O AutoML continuará treinando Modelos de ML até atingir um limite de tempo definido ou um limite definido no número de modelos. Depois que qualquer um desses limites for ultrapassado, ele executará o agrupamento do modelo de aprendizado de máquina usando um conjunto de votação e um conjunto de pilha. Dados de pontuação dos conjuntos de votação com base nas médias ponderadas de seus melhores modelos, enquanto conjunto de pilhas treinam um meta-modelo com base nas previsões de seus melhores modelos.

Depois de treinar nossos modelos de conjunto, o AutoML interromperá a execução e produzirá o melhor modelo. O conjunto de votação ou conjunto de pilha geralmente será nosso modelo de melhor desempenho. Às vezes, no entanto, outro modelo supera ligeiramente os dois.

7.2 Treinando o modelo no AutoML


Após carregarmos os dados de nossa máquina local para nosso Azure Machine Learning Studio (AML Studio), selecionaremos apenas as colunas necessárias para o treinamento. Em seguida, treinaremos um modelo AutoML usando a interface do usuário. Depois de treinar nosso modelo, interpretaremos seus resultados diretamente do portal AMLS. Isso inclui não apenas métricas padrão, como precisão, taxa de falso positivo e taxa de falso negativo, mas também um painel explicativo.

7.2.1 Criando uma solução AutoML

Agora que carregamos os dados de consumo de energia em nosso armazenamento de dados e os registramos como um conjunto de dados, estamos prontos para treinar um modelo AutoML com alguns cliques:


- 1) Clicamos em Automated ML no menu à esquerda em Author. Em seguida, clicamos em New Automated ML job, marcado por uma cruz preta, próximo ao canto superior esquerdo da nova página, conforme mostrado abaixo:

Figura 22 – Iniciando sua execução de treinamento do AutoML



Próprio autor

- 2) Depois de avançar para a próxima tela, veremos todos os conjuntos de dados elegíveis para treinamento. Atualmente, apenas conjuntos de dados tabulares são compatíveis com execuções da GUI do AutoML. Também podemos criar um novo conjunto de dados a partir dessa exibição clicando no botão “Create”. Seleccionamos DS-PI-IV-TAB, conforme mostrado na figura abaixo, e clicamos no botão “Next”:

Figura 23 – Selecionando nosso conjunto de dados para treinamento

Próprio autor

Depois de selecionar nosso conjunto de dados, as próximas etapas envolvem nomear nosso experimento, selecionar uma coluna para prever e selecionar um cluster de computação para treinamento remoto. “Experiments” registra todas as informações relacionadas ao nosso treino.

- 1) Para criar um novo experimento, selecionamos “Create new” e atribua a ele o nome EXPERIMENT-PI-IV-01. Não temos permissão para termos espaços nos nomes dos nossos experimentos; os únicos caracteres especiais permitidos são hifens ou sublinhados.
- 2) Em seguida, selecionamos nossa coluna de destino (Target column) no menu suspenso. Nossa coluna de destino é o número ou classe que nós estamos tentando prever com nosso modelo de aprendizado de máquina. Nesse caso, selecionamos dic (Duração de Interrupção por unidade consumidora).
- 3) Da mesma forma, selecionamos um cluster de computação no qual o AutoML criará modelos de aprendizado de máquina. Selecionamos o cluster de computação que criamos no menu suspenso. O AutoML será executado nesta computação remotamente, permitindo que nós continuemos a fazer outros trabalhos em nosso espaço de trabalho AMLS.
- 4) Confirmamos nossas configurações conforme evidenciado *abaixo* e clicamos em “Next” para avançarmos para a tela final:

Figura 24 – Configurando nossa execução do AutoML

Create a new Automated ML job

1 Select data asset

2 **Configure job**

3 Select task and settings

4 Hyperparameter configuration (Computer Vision only)

5 Validate and test

Configure job
Select from existing experiments or create a new experiment, then select the target column and training compute.
[Learn more on how to configure the experiment.](#)

Data asset
DS-PI-IV-TAB ([View data asset](#))

Experiment name
☐ Select existing ☒ Create new

New experiment name *
EXPERIMENT-PI-IV-01

Target column *
dic (Decimal)

Select compute type
Compute cluster

Select Azure ML compute cluster *
CC-PI-IV
[+ New](#) [Refresh computes](#)

[Back](#) [Next](#)

Próprio autor

- 5) Existem cinco opções no próximo menu: Classification , Regression, Time series forecasting, Natural language processing e Computer vision. A “classification” é para quando queremos prever uma categoria, como se uma pessoa tem probabilidade de inadimplir um empréstimo ou pagá-lo. A “regression” é para quando estamos tentando prever um número em vez de uma classe, por exemplo, tentando prever o preço de um recurso baseado em casa, como seu tamanho. A “time series forecasting”, por outro lado, é para quando estamos tentando prever um número no futuro. A “natural language processing” prevê com base em tipos de dados somente de texto usando classificação de várias classes ou multi-rótulos. Já a “Computer vision” faz a classificação de imagens, detecção de objetos e instância de várias classes ou vários rótulos. Como estamos tentando prever a interrupção de energia em um determinado logradouro, selecionaremos “Regression”. Em seguida pressionamos o botão “Next”. Conforme figura abaixo:

Figura 25 – Selecionando o tipo de tarefa correta

Create a new Automated ML job

- ✓ Select data asset
- ✓ Configure job
- 1 Select task and settings**
- 2 Hyperparameter configuration (Computer Vision only)
- 3 Validate and test

Select task and settings
Select the machine learning task type for the experiment. To fine tune the experiment, choose additional configuration or featurization settings.

- Classification**
To predict one of several categories in the target column, yes/no, blue, red, green.
- Regression**
To predict continuous numeric values. ✓
- Time series forecasting**
To predict values based on time.
- Natural language processing**
Predict based on text-only data types using multi-class or multi-label classification.
- Computer vision**
Multi-class or multi-label image classification, object detection, and instance segmentation.

[View additional configuration settings](#) [View featurization settings](#)

[Back](#) [Next](#)

Próprio autor

5) Na tela seguinte não alteramos os valores padrões e clicamos no botão “Finish”.

Figura 26 – Selecionando os tipos de validação e teste

Create a new Automated ML job

✓ Select data asset

✓ Configure job

✓ Select task and settings

✓ Hyperparameter configuration (Computer Vision only)

5 Validate and test

Select the validation and test type

You can choose a validation type and select a test data asset as an optional step. Providing your own validation and test data assets are currently preview features.

Validation type ⓘ

Auto

Test data asset (preview) ⓘ

No test data asset required

Back

Finish

Próprio autor


8 RESULTADOS

Nosso job de treinamento levou cerca de 12 horas e produziu vários modelos com até 80% de acuracidade. No entanto, há muito mais em nossos resultados do que essa métrica simples. Lá estão proteções de dados que nos informaram sobre quaisquer problemas com nossos dados. Há também uma série de métricas diferentes para cada um dos três tipos de problemas e tabelas e gráficos que podem nos ajudar a apresentar nossos resultados.

8.1 Interpretando nossos resultados do AutoML

- 1) Para começar, clicamos em Automated ML no menu à esquerda do AMLS e clicamos na última execução do nosso job JOB-01-PI-IV *conforme mostrado na figura abaixo*:

Figura 27 – Tela com o último JOB executado



Próprio autor

- 2) Clicamos no job JOB-01-PI-IV e seremos levados a tela “Overview”, depois clicamos em “Models” e veremos uma tela com várias métricas relacionadas ao nosso modelo, incluindo o tipo de algoritmo usado para treinar os modelos de melhor desempenho, sua pontuação de precisão, a data e a hora em que foi criado e quanto tempo sua execução do AutoML levou para executar.

Figura 28 – Tela com os modelos

Algorithm name	Explained	Normalized root mean squared error ↑	Sampling	Created on	Duration	Hyperparameter
StackEnsemble	View explanation	0.00716	100.00 %	May 23, 2023 9:24 AM	14m 32s	algorithm : [XGBoostRegressor] ...
MaxAbsScaler, XGBoostRegressor		0.00720	100.00 %	May 23, 2023 3:21 AM	12m 51s	tree_method : auto ...
VotingEnsemble		0.00720	100.00 %	May 23, 2023 9:23 AM	1m 1s	algorithm : [XGBoostRegressor] ...
MaxAbsScaler, LightGBM		0.00783	100.00 %	May 23, 2023 3:21 AM	1m 9s	min_data_in_leaf : 20 ...
StandardScalerWrapper, ElasticNet		0.01091	100.00 %	May 23, 2023 3:21 AM	3h 47m 57s	alpha : 0.001 l1_ratio : 0.84360 ...
MaxAbsScaler, ElasticNet		0.01228	100.00 %	May 23, 2023 3:21 AM	1h 21m 10s	alpha : 0.001 l1_ratio : 0.68730 ...

Próprio autor

- 3) Existem cinco guias na parte superior da tela: “Overview”, “Data guardrails“, ”Models“, ”Outputs + Logs“, ”Child jobs“. Para fins de interpretação dos resultados, apenas as proteções de dados (Data guardrails) e os modelos (models) são importantes.
- 4) Clicamos na guia “Data guardrails” para vermos os resultados.

Figura 29 – Tela “Data guardrails”

Type	Status	Description
Validation split handling	Done	The input data has been split into a training dataset and a validation dataset for validation of the model. The validation dataset is generated to improve model performance. Learn more about validation data.
Missing feature values imputation	Done	Missing feature values were detected in your training data, and imputed. If the missing values are expected, let the run complete. Otherwise cancel the current run and use a script to customize the handling of missing feature values that may be more appropriate based on the data type and business requirement. Learn more about missing value imputation.
High cardinality feature detection	Passed	Your inputs were analyzed, and no high cardinality features were detected. Learn more about high cardinality feature detection.

Próprio autor

8.1.1 Entendendo as proteções de dados (Data Guardrails)

As proteções de dados identificam e corrigem quaisquer problemas que tenhamos em nosso conjunto de dados e é essencial saber quais são esses problemas. Existem

diferentes proteções, dependendo se nós estamos tentando resolver um problema de classificação, regressão ou previsão. Problemas de regressão usam o seguinte:


- **Validation split handling:** essa proteção analisa o tamanho do conjunto de dados e os valores exclusivos dentro das colunas para determinar como nosso modelo de aprendizado de máquina deve ser treinado e validado. Nosso conjunto de dados foi dividido em dois conjuntos de dados, um de treino com 1819097 linhas (89.99% do total) e outro para teste com 202122 linhas (10% do total).
- **Missing feature values imputation:** essa proteção verificará nossos dados em busca de valores nulos, contá-los e preenchê-los automaticamente. Nosso conjunto de dados apresentou apenas três dados faltantes na coluna `dat_con`.
- **High cardinality feature detection:** essa proteção examinou nossas colunas categóricas e verificou se algum deles tem muitos valores exclusivos; nesse caso, eles serão agrupados. Com nosso conjunto de dados, essa proteção é passada e os dados são deixados inalterados.

8.1.2 Entendendo as métricas do modelo

Depois de explorar a proteção de dados, a próxima etapa envolve a interpretação do nosso modelo:

- 1) Clicamos em “Models” ao lado da guia “Data guardrails”. Nesta guia, nós veremos uma lista de modelos gerados pelo AutoML classificados em ordem de precisão, com o modelo de maior pontuação no topo.

Figura 30 – Tela com os modelos gerados




The screenshot shows the 'Models' tab in the AutoML interface. At the top, there's a status bar for 'JOB-01-PI-IV' which is 'Completed'. Below it are tabs for 'Overview', 'Data guardrails', 'Models' (selected), 'Outputs + logs', and 'Child jobs'. A toolbar contains 'Refresh', 'Deploy', 'Download', 'Explain model', 'View generated code', and 'View options'. A search bar is on the left, and 'Filter' and 'Columns' icons are on the right. The table below lists models sorted by performance.

Algorithm name	Explained	Normalized root mean squared error ↑	Sampling	Created on	Duration	Hyperparameter
StackEnsemble	View explanation	0.00716	100.00 %	May 23, 2023 9:24 AM	14m 32s	algorithm : [XGBoostRegressor] ...
MaxAbsScaler, XGBoostRegressor		0.00720	100.00 %	May 23, 2023 3:21 AM	12m 51s	tree_method : auto ...
VotingEnsemble		0.00720	100.00 %	May 23, 2023 9:23 AM	1m 1s	algorithm : [XGBoostRegressor] ...
MaxAbsScaler, LightGBM		0.00783	100.00 %	May 23, 2023 3:21 AM	1m 9s	min_data_in_leaf : 20 ...
StandardScalerWrapper, ElasticNet		0.01091	100.00 %	May 23, 2023 3:21 AM	3h 47m 57s	alpha : 0.001 l1_ratio : 0.843684 ...
MaxAbsScaler, ElasticNet		0.01228	100.00 %	May 23, 2023 3:21 AM	1h 21m 10s	alpha : 0.001 l1_ratio : 0.687366 ...

- 2) Clicamos no nome do nosso modelo de maior pontuação, isso nos levará a uma tela semelhante com um novo conjunto de guias na parte superior. “Metrics”, a quarta guia na parte superior, contém não apenas precisão, mas todas as métricas e gráficos adicionais associados a um problema de regressão. Podemos marcar e desmarcar qualquer um que desejarmos. Existem 14 caixas de seleção, mas, para essa demonstração, marcaremos nove. Abaixo segue a tela capturada com as métricas selecionadas:

Figura 31 – Métricas do modelo



Próprio autor

Explained variance - A variância explicada mede até que ponto um modelo explica a variação na variável de destino. É a diminuição percentual na variação dos dados originais para a variação dos erros. Quando a média dos erros é 0, é igual ao coeficiente de determinação (ver r2_score abaixo). Quanto mais próximo de 1, melhor. Nosso resultado foi 0.9009201.

Mean absolute error - O erro absoluto médio é o valor esperado do valor absoluto da diferença entre o alvo e a previsão. Quanto mais próximo de 0, melhor. Nosso resultado foi 2.080104.

Mean absolute percentage error - O erro percentual médio absoluto (MAPE) é uma medida da diferença média entre um valor previsto e o valor real. Quanto mais próximo de 0, melhor. Nosso resultado foi 102.9358.

Median absolute error - O erro absoluto mediano é a mediana de todas as diferenças absolutas entre o alvo e a previsão. Essa perda é robusta para outliers. Quanto mais próximo de 0, melhor. Nosso resultado foi 1.256755.

R2 score - R^2 (o coeficiente de determinação) mede a redução proporcional no erro quadrático médio (MSE) em relação à variância total dos dados observados. Quanto mais próximo de 1, melhor. Nosso resultado foi 0.9009195.

Nota: R^2 geralmente tem o intervalo $(-\infty, 1)$. O MSE pode ser maior que a variância observada, portanto R^2 pode ter valores negativos arbitrariamente grandes, dependendo dos dados e das previsões do modelo. Clipes de ML automatizados relataram pontuações de R^2 em -1, portanto, um valor de -1 para R^2 provavelmente significa que a pontuação de R^2 real é menor que -1. Consideremos os outros valores de métricas e as propriedades dos dados ao interpretar uma pontuação R^2 negativa.

Root mean squared log error - Raiz do erro quadrático médio (RMSE) é a raiz quadrada da diferença quadrada esperada entre o alvo e a previsão. Para um estimador imparcial, o RMSE é igual ao desvio padrão. Quanto mais próximo de 0, melhor. Nosso resultado foi 3.826055.

Spearman correlation - A correlação de Spearman é uma medida não paramétrica da monotonicidade da relação entre dois conjuntos de dados. Ao contrário da correlação de Pearson, a correlação de Spearman não assume que ambos os conjuntos de dados são normalmente distribuídos. Como outros coeficientes de correlação, Spearman varia entre -1 e 1 com 0 implicando nenhuma correlação. Correlações de -1 ou 1 implicam uma relação monotônica exata. Spearman é uma métrica de correlação de ordem de classificação, o que significa que as alterações nos valores previstos ou reais não alterarão o resultado de Spearman se não alterarem a ordem de classificação dos valores previstos ou reais. Quanto mais próximo de 1, melhor. Nosso resultado foi 0.8984462.

Predicted vs. true - Para experimentos de regressão e previsão, o gráfico previsto versus verdadeiro plota a relação entre o recurso de destino (valores verdadeiros/reais) e as previsões do modelo. Os valores verdadeiros são agrupados ao longo do eixo x e, para cada categoria, o valor médio previsto é plotado com barras de erro. Isso permite que vejamos se um modelo é tendencioso para prever determinados valores. A linha exibe a previsão média e a área sombreada indica a variação das previsões em torno dessa média. Muitas vezes, o valor verdadeiro mais comum terá as previsões mais precisas com a menor variância. A distância da linha de tendência da linha ideal $y=x$ onde há poucos valores verdadeiros é uma boa medida do desempenho do modelo em outliers. Nós podemos usar o histograma na parte inferior do gráfico para raciocinar sobre a distribuição de dados reais. Incluir mais amostras de dados onde a distribuição é esparsa pode melhorar o desempenho do modelo em dados não vistos.

Residuals - O gráfico de resíduos é um histograma dos erros de previsão (resíduos) gerados para experimentos de regressão e previsão. Os resíduos são calculados como $y_{\text{predicted}} - y_{\text{true}}$ para todas as amostras e exibidos como um histograma para mostrar o viés do modelo. No nosso modelo, observamos que ambos os modelos são ligeiramente


tendenciosos para prever valores maiores que o real. Isso não é incomum para um conjunto de dados com uma distribuição pouco distorcida de alvos reais, mas indica um desempenho melhor do modelo. Um bom modelo terá uma distribuição de resíduos com pico em zero com poucos resíduos nos extremos. Um modelo pior terá uma distribuição de resíduos espalhada com menos amostras em torno de zero.

8.1.3 Explicando nosso modelo AutoML

Conhecer nossos resultados é importante, mas saber como nosso modelo derivou nossos resultados é tão importante quanto. Aqui é onde a explicabilidade do modelo desempenha um papel fundamental. Explicabilidade é a capacidade de dizer quais recursos são mais importante na construção de nosso modelo AutoML. Isso é especialmente importante em setores onde nós precisamos explicar legalmente nossos modelos de aprendizado de máquina, por exemplo, se criamos um modelo para determinar quem é aprovado para um empréstimo:

- 1) Para começar, clicamos na guia “Explantions” ao lado de Metrics.
- 2) Clicamos no primeiro ID em ID de explicação no lado esquerdo da tela.
- 3) Clicamos no item de menu “Model performance”, avaliamos o desempenho do nosso modelo, explorando a distribuição de seus valores de previsão e os valores das métricas de desempenho do nosso modelo. Nós podemos investigar mais nosso modelo analisando uma análise comparativa de seu desempenho em diferentes cortes ou subgrupos do nosso conjunto de dados. Selecionamos os filtros ao longo do valor Y e do valor X para cortar diferentes dimensões. Abaixo segue a captura da tela:


Figura 32 – Tela “Model performance”



Próprio autor

- 4) Clicamos na guia “Dataset explorer” para explorar nossas estatísticas do conjunto de dados selecionando diferentes filtros ao longo dos eixos X, Y e de cor para dividir seus dados em diferentes dimensões. Podemos criar cortes de conjunto de dados acima para analisar estatísticas de conjunto de dados com filtros como resultado previsto, recursos de conjunto de dados e grupos de erros. Podemos usar o ícone de menu no canto superior direito do gráfico para alterar os tipos de gráfico.


Figura 33 – Tela “Dataset explorer”



Próprio autor

- 5) Clicamos na guia “Aggregate feature importance” para visualizar os principais recursos que afetam as previsões gerais do modelo (também conhecido como explicação global). Usamos o controle deslizante para mostrar os valores decrescentes de importância do recurso. Seleccionamos até três cortes para ver seus valores de importância de recursos lado a lado. Seleccionamos qualquer uma das barras de recursos no gráfico para ver como os valores do recurso selecionado afetam a previsão do modelo no gráfico de dependência abaixo:


Figura 34 – Tela “Aggregate feature importance”



Próprio autor

- 6) Clicamos na guia “Individual feature importance” que nos permite detalhar um ponto de dados individual e suas importâncias de recursos individuais. Nós podemos carregar o gráfico de importância de recurso individual para qualquer ponto de dados clicando em qualquer um dos pontos de dados individuais no gráfico de dispersão principal ou selecionando um ponto de dados específico no assistente do painel à direita. Na captura de tela abaixo, estamos demonstrando a distribuição do dado `ogc_fid`:

Figura 35 – Tela “Individual feature importance”



Próprio autor

8.2 PowerBI

O Power BI é uma poderosa ferramenta de análise de dados e visualização desenvolvida pela Microsoft. A ferramenta permite coletar, transformar e visualizar dados de maneira intuitiva, ajudando a transformar informações complexas em insights significativos, análise de dados. É uma ferramenta extremamente versátil e ágil para implementação de Dashboards dinâmicos auxiliando muitas vezes na tomada de decisão para expansão de negócios existentes, novos negócios ou estudos de casos. Com a ferramenta possuímos uma representação visual de informações e dados-chave, apresentados de forma clara e concisa.


Entre os benefícios da ferramenta e temos a possibilidade de monitoramento em tempo real da informação, visualização de forma intuitiva, identificação de padrão e tendências comportamentais que são disponibilização de forma simples para a comunidade externa.

A criação e desenvolvimento desses dashboards utilizando a ferramenta é intuitiva e fácil de aplicação, é possível manipular os dados antes de plotar as informações no Dashboard de forma que é possível criar operações estatísticas para o conjunto de dados. É possível utilizar a linguagem “DAX” (Data Analysis Expressions) desenvolvida pela Microsoft especificamente para uso no Power BI.

8.2.1 Desenvolvimento dos dashboards

Para o desenvolvimento dos dashboards via PowerBI alguns passos foram seguidos como a coleta dos dados desenvolvidos a partir da extração dos dados do modelo AutoML inserido no PowerBi a partir da importação de dados de CSV, conforme apresentado na figura abaixo:

Figura 36 – Inserção de Dados no PowerBi a partir de arquivos CSV



Próprio autor

Após inserir o arquivo contendo os dados no PowerBi realizamos algumas tratativas para melhor exibição do relatório e formatação de alguns campos como o CEP para o PowerBi identificar que se refere a um espaço geográfico a ser representado conforme apresentado na figura abaixo:


Figura 37 – Tratativa dos dados para apresentação visual da aplicação

[illegible]

Próprio autor

Para renderização das visualizações foram utilizados alguns objetos que o PowerBi proporciona como as funções de mapa, segmentação de dados, gráficos em formato de TreeMap e tabela para apresentação dos valores, conforme apresentadas na figura abaixo:


Figura 38 – Montagem do Painel no PowerBi com utilização de Mapa, Tabela, Filtros e TreeMap destacados na ferramenta de opções do PowerBI



Próprio autor

Com a utilização dos recursos disponíveis foi possível criar 3 páginas de análises dos dados, conforme figuras 39,40 e 41. Onde o primeiro painel “Consumo por Residência” apresenta uma visão geral da cidade de Guarulhos plotado em mapa e visualização dos valores em tabela, conforme figura 39. O segundo painel apresenta uma visão macro, onde é possível coletar ‘insights’ do tamanho da amostra de casas da cidade de Guarulhos e com isso analisar onde se encontram as maiores faixas de consumo das residências, com mais da metade compreendendo entre 100 à 300 kWh, conforme figura 40. E no terceiro painel é verificado a qualidade de fornecimento do analisando a quantidade de horas sem energia elétrica por mês e a frequência de interrupções que essas áreas sofreram, conforme visualizado na figura abaixo:

Figura 39 – Painei “Consumo por Residência” Análise de consumo de energia elétrico por residência por CEP




Próprio autor

Figura 40 – Painei “Faixa de consumo por Localização” Análise com Visão TreeMap das faixas de consumo da cidade de Guarulhos



Próprio autor

Figura 41 – Painel “Qualidade da Energia elétrica” Visualização da qualidade de fornecimento de energia elétrica na cidade de Guarulhos



Próprio autor

Com a utilização do filtro é possível escolher determinadas localizações e realizar visualizações específicas para coletar ‘insights’ da região que deseja e com isso nosso painel se transforma dinâmico, conforme figura abaixo:

Figura 42 – “Painel Consumo Por Residência” com o filtro de localidades



Próprio autor

9 CONCLUSÃO

Com o Aprendizado de Máquina Automatizado com o Microsoft Azure, aprendemos como carregar arquivos de nossa máquina local para nosso armazenamento de dados e registrá-los como um conjunto de dados. Nós criamos nosso primeiro modelo AutoML. Interpretamos os resultados do nosso modelo com gráficos e métricas, e explicamos como nosso modelo faz previsões.

Com a análise dos dashboards é possível coletar alguns 'Insights' entre eles podemos destacar com a análise do painel 1 (Consumo Por Residência), é possível identificar uma homogeneidade do consumo na cidade de Guarulhos, porém é possível notar que determinadas regiões se destacam positivamente acima da média da cidade de Guarulhos com consumos elevados.

Verificando o painel 2 (Faixa de Consumo Por Região) como verificação da grande faixa dos consumidores de energia elétrica da cidade de Guarulhos consomem entre 100 a 300 KWh que se encontra dentro da média da região Sudeste de consumo, conforme analisado por (GHIS, 2023).

Analisando o painel 3 (Qualidade da Energia Elétrica) é possível analisar que as regiões mais isoladas da cidade são as mais afetadas pela má qualidade da energia com diversas interrupções no sistema de fornecimento via quantidade de horas sem o fornecimento de energia elétrica.

Referências

- BEACH, D. **Introduction to Data Engineering**. [S.l.]: Leanpub, 2022.
- DEMO, P. **Introdução à Metodologia da Ciência**. [S.l.]: Atlas, 1983.
- FAYYAD, U. From data mining to knowledge discovery in databases. **AI magazine**, v. 17, n. 3, p. 37 – 54, 10 1996.
- GHIS, E. **Usos Finais de Energia Elétrica no Setor Residencial Brasileiro**. 2023. Disponível em: <https://labeee.ufsc.br/node/480#:~:text=Observou%2Dse%20que%20o%20consumo,3%20kWh%2Fm%C3%AAs%20no%20inverno>. Acesso em: 30 Mai. 2023.
- MAZUCATO, T. **Metodologia da Pesquisa e do Trabalho Científico**. [S.l.]: FUNEPE, 2018.
- MUKUNTHU, D.; SHAH, P.; TOK, W. H. **Practical Automated Machine Learning on Azure: Using Azure Machine Learning to Quickly Build AI Solutions**. [S.l.]: O'REILLY, 2019.
- SAYYERS, D. M. **Automated Machine Learning with Microsoft Azure**: Build highly accurate and scalable end-to-end AI solutions with Azure AutoML. [S.l.]: Packt>, 2021.
- SCRATCH, J. **Python for Data Analysis**. [S.l.]: Jason Scratch, 2020.
- WIKIPÉDIA a enciclopédia livre D. **Análise de dados**. 2023a. Disponível em: https://en.wikipedia.org/wiki/Data_analysis. Acesso em: 31 Mai. 2023.
- WIKIPÉDIA a enciclopédia livre D. **Aprendizado de máquina**. 2023b. Disponível em: https://pt.wikipedia.org/wiki/Aprendizado_de_m%C3%A1quina. Acesso em: 31 Mai. 2023.
- WIKIPÉDIA a enciclopédia livre D. **Extração de conhecimento**. 2023c. Disponível em: https://pt.wikipedia.org/wiki/Extra%C3%A7%C3%A3o_de_conhecimento. Acesso em: 31 Mai. 2023.
- WIKIPÉDIA a enciclopédia livre D. **Mineração de dados**. 2023d. Disponível em: https://pt.wikipedia.org/wiki/Minera%C3%A7%C3%A3o_de_dados. Acesso em: 31 Mai. 2023.
- WIKIPÉDIA a enciclopédia livre D. **k-means**. 2023e. Disponível em: <https://pt.wikipedia.org/wiki/K-means>. Acesso em: 31 Mai. 2023.